Modelo Preditivo de Incêndios Florestais

Mateus A. Frutuoso[1], **Gustavo C. Barbosa**[1], **Fabricio Herpich**[1]

[1]Ciência Da Computação – Universidade Federal da Fronteira Sul (UFFS)

Abstract. *Forest fires represent a severe environmental and socio-economic challenge in Brazil, driven by complex interactions among climate, vegetation, and soil. Although vast public databases exist—such as meteorological records from INMET and fire monitoring from INPE—integrating disparate data sources characterized by noise and missing values remains challenging. This paper presents a machine learning-based predictive model using XGBoost to forecast forest fire risks. Following the Design Science Research Methodology (DSRM), an ETL pipeline was developed to merge INMET historical meteorological series with INPE spatial fire records. The XGBoost algorithm was trained, addressing class imbalance via the scale_pos_weight parameter, and deployed into an interactive web application built with Streamlit, which integrates real-time weather forecasts from the Yr API. The results demonstrate an effective, automated, and accessible technological artifact that empowers environmental monitoring agencies to optimize resource allocation and strategic fire suppression.*

Resumo. *Os incêndios florestais representam um desafio ambiental e socioeconômico severo no Brasil, impulsionados por interações complexas entre clima, vegetação e solo. Embora existam vastos bancos de dados públicos—como os registros meteorológicos do INMET e o monitoramento de queimadas do INPE—a integração de fontes heterogêneas marcadas por ruídos e dados faltantes permanece um desafio. Este artigo apresenta um modelo preditivo baseado em Machine Learning utilizando o algoritmo XGBoost para antecipar o risco de incêndios florestais. Seguindo a Design Science Research Methodology (DSRM), desenvolveu-se um pipeline de ETL para unificar séries temporais climáticas do INMET com registros espaciais de queimadas do INPE. O modelo XGBoost foi treinado tratando o desbalanceamento de classes e integrado a uma aplicação web interativa desenvolvida em Streamlit, que utiliza a API do Yr para previsões em tempo real. Os resultados demonstram um artefato tecnológico automatizado e acessível, capaz de apoiar órgãos de monitoramento ambiental na otimização da alocação de recursos e estratégias de prevenção.*

1. Introdução

Os incêndios florestais são um desafio ambiental e socioeconômico significativo no Brasil, suas ocorrências são frequentemente determinadas por interações complexas entre o clima, a vegetação e o solo [Faria et al. 2026]. Embora existam vastos bancos de dados públicos disponíveis, como os dados climáticos fornecidos pelo Instituto Nacional de Meteorologia (INMET) e o monitoramento do Programa Queimadas do Instituto Nacional de Pesquisas Espaciais (INPE), antecipar incêndios florestais de forma precisa usando apenas métodos tradicionais ainda é um desafio. A complexidade desse problema está na

integração de variáveis de tipos distintos, como séries temporais climáticas e dados geoespaciais, que muitas vezes apresentam ruídos ou falta de dados, além do grande volume de informações a serem analisadas.

Historicamente, o mapeamento de risco utilizando técnicas de geoprocessamento foi a ferramenta principal para monitorar essas áreas, porém recentemente, novas abordagens estão sendo adotadas. No contexto atual, onde nossa capacidade computacional permite analisar grandes volumes de informações em tempo real, identificando padrões antes imperceptíveis, a transição de métodos puramente reativos para abordagens preditivas torna-se fundamental [Chen et al. 2025]. O uso de mineração de dados associada a variáveis meteorológicas e a aplicação de Inteligência Artificial para predição de incêndios florestais [Cortez and Morais 2007], por exemplo, já nos mostra resultados significativos, mas esbarram no desafio de unificar fontes de dados distintas e com ruído considerável.

Dessa forma, a principal questão deste trabalho é: *Como integrar dados meteorológicos e registros históricos geoespaciais em um modelo computacional preditivo para antecipar com eficácia o risco de incêndios florestais no Brasil?*

A criação deste modelo justifica-se pela urgência na preservação de ecossistemas vulneráveis, em especial os biomas Amazônia e Cerrado, que são os mais afetados pelas queimadas [Instituto Nacional de Pesquisas Espaciais (INPE) 2026]. O desenvolvimento de ferramentas tecnológicas preditivas de suporte permitirá que órgãos de monitoramento e preservação ambiental aloquem seus recursos de combate a incêndios de forma mais otimizada, estratégica e eficiente.

Portanto, o objetivo principal deste projeto é: *Desenvolver um modelo preditivo de incêndios florestais, utilizando Machine Learning, que integre os dados abertos do INMET e do INPE para identificar antecipadamente áreas de risco.*

2. Trabalhos Relacionados

Em um estudo pioneiro, [Cortez and Morais 2007] desenvolveram uma abordagem utilizando mineração de dados para prever incêndios florestais a partir de variáveis meteorológicas. O estudo demonstrou a viabilidade da utilização de dados climáticos históricos para alimentar modelos preditivos de inteligência artificial, obtendo maior acurácia na previsão de risco de incêndios além de tornar o processo mais automatizado e menos dependente de análises manuais.

Em uma perspectiva mais recente, [Chen et al. 2025] analisaram os avanços e aplicações de Inteligência Artificial voltados especificamente para a predição de incêndios florestais. Os autores evidenciam a importância da transição de métodos puramente reativos para abordagens preditivas, visto o aumento da capacidade computacional para processar grandes volumes de informações e identificar padrões antes imperceptíveis.

Trazendo a análise para o contexto ambiental brasileiro, [Faria et al. 2026] investigaram as interações complexas entre clima, vegetação e solo na predição do risco de incêndios. A pesquisa focou no monitoramento de unidades de conservação do bioma Mata Atlântica no Brasil, evidenciando o impacto dos fatores geoespaciais e ambientais locais na ocorrência de queimadas.

Apesar das contribuições relevantes desses estudos, a maioria tem seu foco em

métodos tradicionais de geoprocessamento ou lida de forma isolada com as variáveis selecionadas. O diferencial desta pesquisa está na integração robusta de dados de diferentes naturezas, unindo as séries temporais meteorológicas do INMET com os registros espaciais de queimadas do INPE. Diferente das abordagens anteriores, este trabalho propõe um modelo computacional preditivo em Machine Learning preparado para lidar com ruídos e dados faltantes em bases públicas brasileiras de grande volume, oferecendo uma ferramenta prática, acessível e otimizada para o monitoramento e preservação das áreas rurais do território nacional.

3. Referencial Teórico

3.1. Mineração de Dados (Data Mining)

A Mineração de Dados consiste no processo de exploração de grandes volumes de dados para descobrir padrões consistentes, anomalias e correlações. No contexto de monitoramento ambiental, essa etapa é um requisito crítico para lidar com o grande volume de informações provenientes de bancos de dados públicos. Como essas bases frequentemente apresentam ruídos, inconsistências ou falta de dados, a mineração aplica técnicas de limpeza e pré-processamento que garantem a extração confiável de variáveis meteorológicas e espaciais [Cortez and Morais 2007].

3.2. Machine Learning (Aprendizado de Máquina)

Como uma subárea da Inteligência Artificial, o Machine Learning baseia-se no desenvolvimento de modelos computacionais capazes de aprender e melhorar seu desempenho a partir da exposição contínua a dados, sem a necessidade de programação específica para cada regra. É essa capacidade analítica que viabiliza a transição de métodos de monitoramento puramente reativos para abordagens estritamente preditivas, integrando dados de naturezas distintas de forma automatizada [Chen et al. 2025].

3.3. XGBoost (Extreme Gradient Boosting)

O XGBoost (*Extreme Gradient Boosting*) é um algoritmo de aprendizado supervisionado baseado em árvores de decisão impulsionadas por gradiente (*gradient boosting*), amplamente reconhecido por sua alta eficiência e desempenho em problemas de classificação tabular [Chen et al. 2025]. No escopo deste modelo preditivo, o algoritmo é empregado para estimar o risco dicotômico de ocorrência de incêndios florestais a partir de múltiplas variáveis independentes. Além disso, o XGBoost oferece suporte robusto para lidar com bases de dados desbalanceadas por meio de parâmetros específicos de ajuste de peso entre classes.

3.4. Dinâmica de Incêndios Florestais e Variáveis Ambientais

A ocorrência e a propagação de incêndios florestais no território brasileiro são fenômenos determinados por interações complexas entre o clima, a vegetação e as condições do solo. Para modelar essa dinâmica computacionalmente, é necessário integrar variáveis de naturezas distintas, combinando séries temporais climáticas, como as fornecidas pelo Instituto Nacional de Meteorologia (INMET), com registros geoespaciais de monitoramento, como os do Programa Queimadas do Instituto Nacional de Pesquisas Espaciais (INPE). Compreender a correlação ambiental entre a ausência prolongada de precipitação, a baixa umidade e a vulnerabilidade de ecossistemas específicos, é absolutamente necessário para justificar a seleção dos atributos que alimentarão o modelo preditivo [Faria et al. 2026].

4. Metodologia

Para o desenvolvimento deste trabalho, adota-se a abordagem Design Science Research Methodology (DSRM), proposta por [Peffers et al. 2007], voltada para a criação e avaliação de artefatos tecnológicos. O processo metodológico divide-se nas seis etapas sequenciais a seguir:

- **Identificação do Problema:** A previsão de incêndios florestais no território brasileiro é um grande desafio devido à complexidade de integrar dados de diferentes naturezas (séries temporais meteorológicas e dados geoespaciais), que frequentemente possuem ruídos e ausência de dados consistentes.
- **Definição dos Objetivos:** Desenvolver um modelo computacional preditivo baseado em Machine Learning capaz de integrar dados meteorológicos e registros históricos para antecipar com eficácia o risco de incêndios florestais.
- **Design e Desenvolvimento:** Construção da arquitetura do modelo, que utilizará o algoritmo XGBoost, e de seu fluxo de processamento de dados (rotinas de limpeza, tratamento de inconsistências e pré-processamento das bases públicas do INMET e do INPE).
- **Demonstração:** Execução do modelo construído para simular a estimativa do risco dicotômico de ocorrência de incêndios em cenários reais do território nacional utilizando o framework *streamlit* integrado à API de dados climáticos do *Yr*.
- **Avaliação:** Mensuração do desempenho do modelo preditivo por meio de métricas quantitativas de avaliação (precisão e capacidade de generalização), validando sua eficácia diante das variações regionais brasileiras.
- **Comunicação:** Demonstração dos resultados e submissão deste artigo científico à comunidade acadêmica, além do compartilhamento das descobertas com órgãos de monitoramento ambiental.

5. Desenvolvimento

O desenvolvimento do sistema foi estruturado em etapas que englobam desde a engenharia de dados até a disponibilização do artefato tecnológico para o usuário final.

5.1. ETL (Extração, Transformação e Carga)

A primeira etapa consistiu no processo de ETL para unificar as bases de dados heterogêneas do INMET e do INPE. Na fase de **Extração**, foi realizada uma varredura em lote utilizando a biblioteca *glob* para capturar todos os arquivos meteorológicos armazenados em diretórios locais. Como os arquivos do INMET continham metadados textuais (como o nome da estação/cidade na primeira linha) antes do cabeçalho tabular a partir da 11ª linha, o script automatizou a leitura dessas linhas iniciais, injetando o nome da localidade como uma nova coluna de identificação nos dados climáticos.

Na fase de **Transformação**, aplicou-se um rigoroso processo de padronização textual para unificar variações ortográficas (removendo acentuações e padronizando maiúsculas/minúsculas, como ”BRASILIA”e ”BRASÍLIA”). As colunas temporais foram convertidas para o padrão analítico *Ano-Mês*. Em seguida, procedeu-se à **Carga** e cruzamento das bases utilizando uma chave composta baseada em *[Nome da Cidade, Ano-Mês]*.

Durante o tratamento de valores nulos, decorrentes de meses sem registros de focos de queimadas em determinadas localidades, implementou-se uma regra de negócio: meses com mais de 10 focos catalogados receberam rótulo binário 1 (risco alto), enquanto os demais receberam 0 (risco baixo).

5.2. Treinamento do Modelo Preditivo

Com a base consolidada, o treinamento do modelo foi realizado utilizando o algoritmo XGBoost. Para lidar com o desbalanceamento inerente ao problema (visto que meses com risco alto são estatisticamente menos frequentes que meses com risco baixo), utilizou-se o parâmetro *scale_pos_weight*. Esse parâmetro calcula a proporção entre classes majoritárias e minoritárias, forçando o algoritmo a penalizar fortemente os erros de falsos negativos (quando um incêndio real é ignorado pelo modelo).

Durante a análise de importância das variáveis (*feature importance*), constatou-se que a variável *PrecipTotal* (precipitação total acumulada) exerceu o peso de decisão mais crítico para a classificação. Após a otimização, o modelo treinado foi serializado e exportado utilizando a biblioteca *joblib* em um arquivo com extensão `.pkl`.

5.3. Resultados

Para tornar o artefato acessível e interativo, desenvolveu-se uma interface de front-end utilizando o framework *Streamlit*, como ilustrado na Figura 1. Nela, o mapa exibe o território brasileiro em destaque com restrição de navegação e visualização externa em tons neutros, permitindo que o usuário explore livremente os municípios e selecione múltiplos pontos de interesse. Cada localidade consultada exibe uma marcação colorida por meio de um gradiente contínuo com base na probabilidade de risco prevista, cujas informações permanecem persistidas no mapa para análises comparativas simultâneas.



Figura 1. Interface gráfica do sistema de predição de incêndios florestais baseada em geolocalização e aprendizado de máquina.

Do ponto de vista arquitetural, o sistema emprega mecanismos de cache para carregar o modelo preditivo serializado na memória apenas na inicialização do servidor, otimizando o tempo de resposta das consultas. Adicionalmente, para a obtenção

de condições meteorológicas em tempo real, a aplicação integra-se à API de previsão do tempo *Yr* (`https://www.yr.no/en`), automatizando a recuperação de parâmetros vigentes para a coordenada selecionada.

Após a coleta e estruturação dos dados em um *DataFrame* compatível com o formato de treinamento, a instância é submetida ao modelo XGBoost. Por fim, o método *predict_proba* calcula a probabilidade matemática do evento de incêndio, traduzindo o resultado em indicadores visuais intuitivos na barra lateral, compostos por alertas textuais categorizados, barras de progresso e métricas detalhadas de temperatura e precipitação projetada.

6. Conclusão

Este trabalho apresentou o desenvolvimento e a implementação de um modelo computacional preditivo para a antecipação de riscos de incêndios florestais no Brasil, integrando com sucesso as bases de dados abertas do INMET e do INPE. Por meio de um robusto processo de ETL e da aplicação do algoritmo XGBoost, foi possível contornar os desafios de desbalanceamento de classes e ruídos inerentes às fontes públicas de grande volume. A disponibilização do artefato tecnológico por meio de uma interface interativa em *Streamlit*, acoplada à API de previsões meteorológicas em tempo real do *Yr*, comprovou a viabilidade prática da ferramenta para apoiar órgãos de fiscalização e conservação ambiental na tomada de decisões estratégicas.

Como trabalhos futuros, sugere-se a expansão da granularidade temporal dos dados (migrando de registros mensais para diários ou horários), a inclusão de novas variáveis geoespaciais e de cobertura do solo (como índices de vegetação NDVI obtidos por imagens de satélite), além da aplicação de técnicas avançadas de explicabilidade de IA (*XAI*) para fornecer maior transparência sobre os fatores que influenciam diretamente as predições geradas.

Referências

Chen, Y., Wang, H., et al. (2025). Advancements in artificial intelligence applications for forest fire prediction. *Forests*, 16(4):704.

Cortez, P. and Morais, A. J. R. (2007). A data mining approach to predict forest fires using meteorological data. In *New Trends in Artificial Intelligence: Proceedings of the 13th EPIA 2007 - Portuguese Conference on Artificial Intelligence*, pages 512–523. APPIA.

Faria, A. L. R. et al. (2026). Climate-vegetation-soil interactions in wildfire risk prediction: Evidence from two atlantic forest conservation units, brazil. *Forests*, 17(5):526.

Instituto Nacional de Pesquisas Espaciais (INPE) (2026). Programa queimadas. Disponível em: ¡https://terrabrasilis.dpi.inpe.br/queimadas/portal/¿. Acesso em: 10 ago. 2026.

Peffers, K., Tuunanen, T., Rothenberger, M. A., and Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77.